


Régression logistique en grande dimension



Plan

- o Définition & but: Régression logistique
- o Simulation des données
- o Calcul des gradients
- o Descente de gradient par coordonnée
- o Descente de gradient par coordonnée avec une pénalisation

Définition

- Modèle sur la loi Y_i sachant X_i :


$$\mathbb{P}(y_i = 1 \mid x_i) = \sigma(x_i^\top w + b) \quad \text{avec} \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

- But: estimer w et b en maximisant la vraisemblance conditionnelle Y_i sachant X_i

$$f(w, b) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, x_i^\top w + b).$$

où $\ell(y, y') = \log(1 + e^{-yy'})$: la perte logistique

Simulation des données



- $n = 1000$
- $d = 2$
- X_i gaussiennes de la loi $N(0, \Sigma)$
- $b = -1$
- $w_j = (-1)^{j-1} e^{-j/10}$

Calcul des gradients

o La dérivée première de $f(w)$ par rapport à w_j

$$\begin{aligned}\frac{\partial f(w)}{\partial w_j} &= \frac{1}{n} \sum_{i=1}^n \frac{-y_i x_i^j e^{-y_i x_i^\top w_j}}{1 + e^{-y_i x_i^\top w_j}} \\&= \frac{1}{n} \sum_{i=1}^n y_i x_i^j \left(\frac{-e^{-y_i x_i^\top w_j}}{1 + e^{-y_i x_i^\top w_j}} \right) \\&= \frac{1}{n} \sum_{i=1}^n y_i x_i^j \left(1 - \frac{1}{1 + e^{-y_i x_i^\top w_j}} \right) \\&= \frac{1}{n} \sum_{i=1}^n y_i x_i^j (1 - \sigma(y_i x_i^\top w_j))\end{aligned}$$

Descente de gradients par coordonnée

- Permutation

- Descente de gradient pour la coordonnée:


$$w_j = w_j - \eta_j \frac{\partial f}{\partial w_j}(w)$$

- Pas de descente:

$$\frac{\partial^2 f}{\partial w_j^2}(w) \leq \frac{\|x^j\|_2^2}{4n}$$

Descente de gradients par coordonnée

o Application de l'algorithme



Fonction minimisée 0.5218959782434925

Estimation des coefficients: [-0.75464262 0.78532741 -0.56742712 0.46433992 -0.42892956 0.45837016

```
-0.41484871 0.16703482 -0.11996869 0.22916815 -0.1741995 -0.06556425
0.10236105 -0.06260438 0.0469528 -0.05263898 -0.02836842 -0.04624102
0.09878094 -0.13044413 0.14652444 -0.01121223 0.09414709 -0.08827123
-0.02848357 -0.0948177 0.05506747 0.15130148 -0.14946212 -0.01978351
0.03050244 0.00580419 0.07838211 0.04819671 -0.04697173 0.00224675
-0.00083915 -0.09416361 -0.03607725 0.00187564 0.09980956 -0.07353569
-0.07287572 0.05340519 -0.1051958 0.13670072 -0.0479342 0.0993725
0.0080196 -0.06584028 0. ]
```

Descente de gradients par coordonnée avec pénalisation

o Technique fondamentale: utilisation d'une pénalisation

→ Pénalisation Lasso:

$$\frac{1}{n} \sum_{i=1}^n \ell(y_i, x_i^\top w + b) + \lambda \|w\|_1$$

Avec λ niveau de pénalisation et

$$\|w\|_1 = \sum_{j=1}^d |w_j|.$$

Descente de gradients par coordonnée avec pénalisation

- o Nouvelle descente de gradient:

$$w_j = s_{\lambda\eta_j} \left(w_j - \eta_j \frac{\partial f}{\partial w_j}(w) \right)$$

avec la fonction de *seuillage doux*:

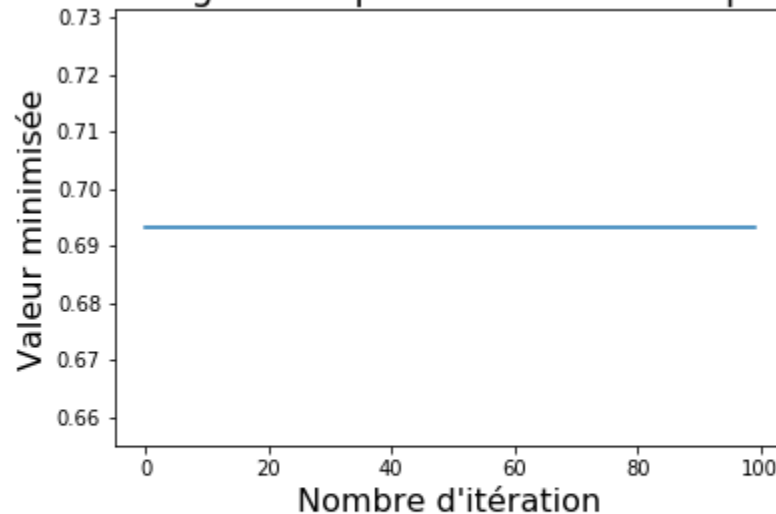
$$s_t(z) = \text{sign}(z)(|z| - t)_+$$

- o Application de l'algorithme avec plusieurs niveaux de pénalisation différents

Descente de gradients par coordonnée avec pénalisation

o Pour $\lambda = 0,5$:

Descente de gradient par coordonnée avec pénalisation



Fonction minimisée 0.6931471805599322

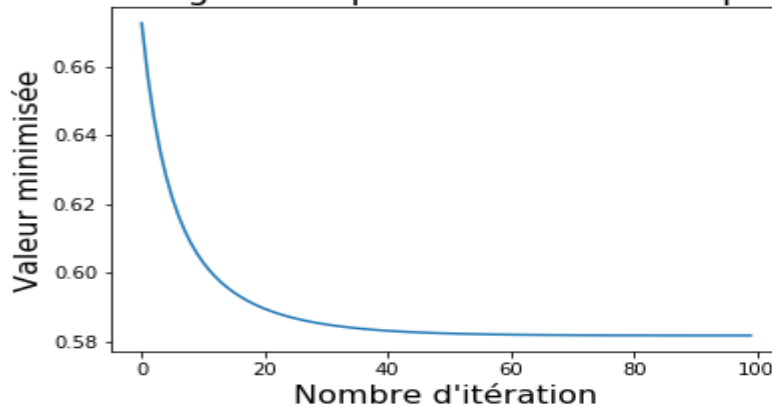
[illegible]

[illegible]

Descente de gradients par coordonnée avec pénalisation

○ Pour $\lambda = 0,01$:

Descente de gradient par coordonnée avec pénalisation



Fonction minimisée 0.5306567617094848

Estimation des coefficients: [-6.90770882e-01 7.24605888e-01 -5.22987424e-01 4.12968936e-01
-3.85033898e-01 4.06033485e-01 -3.53436411e-01 1.12496162e-01
-7.24200722e-02 1.58810662e-01 -1.31273787e-01 -2.32826153e-02
3.51443273e-02 -3.94942466e-03 0.00000000e+00 -1.64624247e-02
-2.09767657e-02 -2.21620215e-04 2.90799822e-02 -5.81309580e-02
1.00937813e-01 0.00000000e+00 3.59043458e-02 -5.04795540e-02
-1.43937834e-03 -4.79521763e-02 1.21492777e-02 1.11492045e-01
-1.03918724e-01 0.00000000e+00 6.95332034e-03 0.00000000e+00
6.11390632e-02 9.42681464e-03 0.00000000e+00 0.00000000e+00
0.00000000e+00 -7.82640092e-02 -4.02964320e-03 0.00000000e+00
4.47495819e-02 -3.67683503e-02 -3.07611991e-02 0.00000000e+00
-4.49847623e-02 8.55899949e-02 0.00000000e+00 4.00902326e-02
0.00000000e+00 -3.44104842e-02 0.00000000e+00]